行動計量学 第 50 巻第 2 号（通巻 99 号）
2023 年，61〜79

原　著

推定精度とモデル選択の関係についての導入的考察

藤 田 和 也

Considering the Relationship Between Estimation Precision and Model Selection

Kazuya Fujita

Estimation, statistical testing, and model selection are the main focus area in statistics. This study focuses on the relationship between estimation precision (Fisher information) and model selection (Kullback–Leibler or KL information). This relationship is important because researchers often conduct estimations or statistical tests after model selection. Additionally, this study examines how Computerized Adaptive Testing (CAT), a stimulus selection method that maximizes Fisher information, affects model selection performance. A simulation study demonstrates the relationship between the difference in Fisher information between two models and the degree of asymmetry in KL information. Furthermore, we confirm that controlling Fisher information using stimulus selection can influence model selection performance. A simulation study suggests that increasing the Fisher information of a false model reduces model selection performance.

Key words: Fisher information, Kullback–Leibler information, adaptive stimulus selection, model selection, estimation precision

キーワード：フィッシャー情報量，Kullback–Leibler 情報量，適応的刺激選択，モデル選択，推定精度

1. 序

データ分析において主要な行為は，推定，検定，モデル選択の 3 つであろう．点推定あるいは区間推定から議論する論文，検定結果により議論する論文，モデル選択結果が直接結論となる論文などがあるが，これら推定，検定，モデル選択は直接的に結論を決めるため重要である．特に，パラメータの推定精度は高く，検出力は高く，正しいモデルを正しくモデル選択できる確率（モデルリカバリ率）も高い方が研究結果は信頼できる．

これら統計的行為のパフォーマンス（推定精度，検出力，モデルリカバリ率）は様々な要因に影響を受けるが，実験者がコントロールできる要因として，サンプリングするデータ数や実験課題構造あるいは実験刺激がある (Heck & Erdfelder, 2019; Murphy & Brincke, 2018)．例えば，検出力の観点からサンプルサイズを決定するサンプルサイズ設計 (Lakens, 2022; Schonbrodt & Wagenmakers, 2018) が近い領域である．統計的な基準によって，とるべきデータ数や実験刺激などの実験デザインを決めることができる．実験刺激とは，質問紙調査における質問項目，学力測定におけるテスト問題，認知課題における参加者に提示する刺激（e.g., 記銘してもらう単語，ギャンブル課題における報酬額や報酬確率）である．

詳しくは 2 節で説明するが，基本的に実験デザインや実験刺激選択を考える際には，対応する統計的な量を考えればよい．例えば，推定精度はフィッシャー情報量（以降，F 情報量）と関係し，モデル選択は Kullback–Leibler（KL）情報量と関係する．推定精度に関しては，ある条件を満たす推定量の分散の下限は分かっており（情報量不等式），最尤推定量は漸近的にその下限を達成する（漸近有効性）ことが分かっている (Chang, 2015)．その分散の値がパラメータが 1 次元の場合は，F 情報量の逆数となる．つまり，F 情報量を最大化しておけば，推定精度（分散の逆数）は最

名古屋大学情報学研究科
（Graduate School of Informatics, Nagoya University）
連絡先：〒 464–8601　愛知県名古屋市千種区不老町
E-mail：fujita.kazuya@k.mbox.nagoya-u.ac.jp

大化されるのである．パラメータが多次元の場合は，F 情報行列で表現される．さらに，F 情報量と検出力の関係も一部で明らかにされている (Ogungbenro & Aarons, 2008a, b, 2010a, b; 竹内他, 2003)．基本的に，F 情報量が大きいほど検出力は大きくなる．

モデル選択に関しては，関連する量の一つとしては KL 情報量が考えられる．KL 情報量とはモデル A とモデル B の違いや離れ具合を表すような量であり，対数尤度の平均的挙動と捉えることができる．少なくとも，推定や検定とモデル選択では，関連する統計的量は表面上異なる．

刺激選択研究に関しては，推定精度を最大化する手法として Computerized Adaptive Testing (CAT; Meijer & Nering, 1999; van der Linden, 2018; Weiss & Kingsbury, 1984) がある．上記の説明の通り，推定精度を向上させる CAT では，F 情報量を最大にするように刺激を選択する．パラメータが多次元の場合は，様々な規準があるが，その一つとして F 情報行列の行列式を最大化する手法が提案されている (Segall, 1996)．なお, adaptive とは参加者の反応データを見てから（パラメータ推定値を暫定的に得てから）参加者に合わせて刺激を選択する手法を指す．また，CAT を含んだ一般的な刺激選択の枠組みとして Adaptive design optimization (ADO; Cavagnaro et al., 2010; Cavagnaro et al., 2013a, b; Myung et al., 2013; Myung & Pitt, 2009; Zhang & Lee, 2010) が提案されている．推定の不確実性，エントロピーを減らすエントロピーベースの手法や Ψ メソッド (Bak & Pillow, 2018; DiMattina, 2015; Kujala & Lukka, 2006; Kontsevich & Tyler, 1999) と呼ばれる類似手法などの，推定精度を良くするための ADO (Ahn et al., 2020; Kim et al., 2014; Lesmes et al., 2015) も存在するが，モデル選択の観点からの刺激選択も提案されている (Cavagnaro et al., 2013a, b; Myung & Pitt, 2009)．モデル選択の観点からの ADO における一つの刺激選択規準として KL 情報量が提案されている (Cavagnaro et al., 2010)．本研究においては刺激選択の手法としては特に CAT の方に注目する．

推定，検定，モデル選択は個別の行為としては，統計的な挙動が比較的研究されているが（e.g., 漸近有効性や検出力の計算式など），各行為の関係性については不明な部分がある．特に本研究ではパラメータ推定の推定精度とモデル選択の関係に着目する．AIC の式を考えると，点推定値を使っているため，推定とモデル選択は同時に行っていると考えられる．またモデル選択した後に，そのモデルでの推定値について議論したり，そのモデルを仮定して検定するという手続きが自然であろう．モデル誤指定の問題を緩めるために Model averaging (Hinne et al., 2022; Hoeting et al., 1999; Wasserman, 2000) を利用する研究もあるが，モデル選択を間違えたら，検定結果などは歪む場合がある．そのため，研究のプロセスや目的にも依存するが，モデル選択と検定のパフォーマンスをバランスよく同時に向上させることが望ましい場合もある．

刺激選択，特に CAT の研究領域に関して言えば，CAT により推定精度を最大化すると，モデル選択のパフォーマンスにはどのように影響するかが不明である．累積プロスペクト理論 (Cumulative Prospect Theory, CPT; Tversky & Kahneman, 1992) モデルに対して CAT を行った先行研究 (Fujita and Okada, 2022) では，F 情報量の計算時に仮定したモデルが選ばれる確率が上昇する場合があることが示されている．F 情報量がモデル選択に影響する可能性は示唆されたが，モデル選択は副次的な関心であったこともあり，F 情報量と KL 情報量がどのような関係なのか，や F 情報量をコントロールすることで明示的にモデル選択のパフォーマンスをコントロールできるかは確認されていない．

そこで本研究では，F 情報量と KL 情報量の関係を考察する．また CAT などの刺激選択法がモデル選択のパフォーマンスにどのように影響するのかを検討することを目的とする．これは実験において，モデル選択と推定精度あるいは検出力を最適化するために知る必要がある．なぜなら先述の通り，モデル選択した後に推定したり検定したりする状況もあり，複数の統計的行為をバランスよく，パフォーマンスを向上させる実験デザインで実験を行いたいからである．あるいは純粋に統計理論としても，F 情報量（推定）と KL 情報量（モデル選択）の関係は興味深いトピックである．

本研究では，理論的挙動を調べるために，パラメータ真値を利用して，F 情報量と KL 情報量を計算し，それらの関連を検討する．また，シミュレーション実験により，様々な F 情報量ベースの刺激選択法によるモデルリカバリ率の違いを比較することで，F 情報量がモデル選択のパフォーマンスに及ぼす影響について検討する．

第 2 節では CAT や KL 情報量など統計的な理論に関する説明を行う．第 3 節でシミュレーション実験の

説明を行い，第 4 節で総合考察を行う．

2. 方　　法

2.1. F 情報量と CAT

$\boldsymbol{\theta}_i^*$，$\widehat{\boldsymbol{\theta}}_i$ を参加者 i $(i = 1, \ldots, N)$ のパラメータの真値および最尤推定量とする．適切な条件の下で，最尤推定量 $\widehat{\boldsymbol{\theta}}_i$ は

$$\widehat{\boldsymbol{\theta}}_i \xrightarrow{d} Norm\left(\boldsymbol{\theta}_i^*,\ \boldsymbol{F}\left(\boldsymbol{\theta}_i^*\right)^{-1}\right) \tag{1}$$

を満たす．ただし，$\boldsymbol{F}\left(\boldsymbol{\theta}_i\right)$ は点 $\boldsymbol{\theta}_i$ における F 情報行列である．F 情報行列 (チュートリアル論文：Ly et al., 2017) は

$$\boldsymbol{F}(\boldsymbol{\theta}_i) = \mathrm{E}\left[\left\{\frac{\partial}{\partial \boldsymbol{\theta}_i}\log L\left(\boldsymbol{\theta}_i; y_{ij}\right)\right\}\left\{\frac{\partial}{\partial \boldsymbol{\theta}_i}\log L\left(\boldsymbol{\theta}_i; y_{ij}\right)\right\}'\right] \tag{2}$$

と定義される．ただし，$L\left(\boldsymbol{\theta}_i; y_{ij}\right)$ は尤度関数，y_{ij} は参加者 i の試行 j の観測データ，「'」は転置記号を表す．F 情報行列はパラメータ $\boldsymbol{\theta}_i$ が p 次元ベクタの場合は，p × p 行列となる．なお F 情報行列や対数尤度は刺激の項も含み，刺激にも依存するが，$\boldsymbol{F}\left(\boldsymbol{\theta}_i\right)$ などの表記に関しては慣習的に刺激の項は省略する．式 (1) から，パラメータが 1 次元の場合は，F 情報量を最大化すれば，推定精度が最大化されることが分かる．1 節で述べたように，パラメータが多次元の場合の刺激選択基準の一つが F 情報行列の行列式最大化であり，D 最適化と呼ばれることもある (Mulder & van der Linden, 2009).

CAT は adaptive な刺激選択法である．つまり，j 試行目までのデータが得られた時に，参加者の j 試行目までの反応データを見てから，j+1 試行目の提示刺激を選択する．$\boldsymbol{F_{1:j}}(\widehat{\boldsymbol{\theta}_i})$ を 1 から j 試行目までの F 情報行列とする．ただし，推定値 $\widehat{\boldsymbol{\theta}_i}$ は 1 から j 試行目までのデータから推定した推定値である．j 試行目までの F 情報量は各試行の単純和で計算できる．j+1 試行目で特定の刺激を提示した場合の F 情報行列を $\boldsymbol{F_{j+1}}(\widehat{\boldsymbol{\theta}_i})$ と書くと，D 最適化では

$$\det(\boldsymbol{F_{1:j}}(\widehat{\boldsymbol{\theta}_i}) + \boldsymbol{F_{j+1}}(\widehat{\boldsymbol{\theta}_i})) \tag{3}$$

という量を刺激選択基準として，これを最大化する刺激を j+1 試行目の刺激として提示する．なお，式 (3) が刺激選択基準となり，この量を刺激を変えて計算する必要がある．この時，刺激の項は省略していることに注意が必要だが，j+1 試行目の刺激候補の値によって $\boldsymbol{F_{j+1}}(\widehat{\boldsymbol{\theta}_i})$ の値が変わる．j 試行目までは刺激も反応データも確定しているため，$\boldsymbol{F_{1:j}}(\widehat{\boldsymbol{\theta}_i})$ は j+1 試行目の各刺激候補間で変わらない．$\boldsymbol{F_{j+1}}(\widehat{\boldsymbol{\theta}_i})$ のみであれば今回のモデルの場合，行列式が 0 に退化してしまうため，$\boldsymbol{F_{1:j}}(\widehat{\boldsymbol{\theta}_i})$ も含めて計算している．なお，従来の CAT は式 (3) のように特定のモデルにおける F 情報行列の行列式を基本的に刺激選択基準として用いる．一方で本研究では，モデル A の F 情報行列の行列式と，モデル B の F 情報行列の行列式の差分を刺激選択基準とする方法も検討する（2.2 節および 3 節のシミュレーション実験で触れる）．つまり，モデル B の推定精度が上がることに対してペナルティを掛けるわけである．

2.2. KL 情報量と F 情報量

KL 情報量は，真の分布を q，仮定した分布を p とした時，

$$KL(q;\ p) = \int q(x)\log\frac{q(x)}{p(x)}dx \tag{4}$$

と定義される (小西・北川, 2004)．KL 情報量は，真のモデル q と仮定したモデル p の近さを測る測度と捉えられている．KL 情報量は，非負値であり，$KL(q;p)$ と $KL(p;q)$ は一般に一致するとは限らない．つまり KL 情報量は非対称な量である．ベルヌーイ分布を仮定する意思決定モデルの場合は，KL 情報量は

$$E_q\left[\log\frac{p\left(\boldsymbol{y}|\boldsymbol{\theta_q^*}\right)}{p\left(\boldsymbol{y}|\boldsymbol{\theta_p^*}\right)}\right] = \sum_t^T \eta_t^*\log\frac{\eta_t^*}{\eta_t} + (1-\eta_t^*)\log\frac{1-\eta_t^*}{1-\eta_t} \tag{5}$$

となる．ただし，$\boldsymbol{\theta_q^*}$，$\boldsymbol{\theta_p^*}$ は真の分布および仮定した分布でのパラメータ真値，η_t^*，η_t は真の分布，仮定した分布での選択肢 A の選択確率である．

2.2 節のこれ以降の説明は，理論的に難解な部分を含むため，統計理論に興味がない読書は読み飛ばして構わない．興味のある読者は，詳しくは情報幾何学関連の書籍を参照して欲しい (e.g., 甘利, 2014; 甘利・長岡, 1993; 藤岡, 2021; 藤原, 2015; 竹内他, 2003)．情報幾何学の文脈では，フィッシャー計量（以降，F 計

量）を入れたのちに，KL ダイバージェンスを特殊例として含むダイバージェンスは入れられている (藤岡, 2021; 藤原, 2015)．また大域的な長さを局所的な長さの足しあげと考えることにより (藤岡, 2021, 3 章)，F 情報量と KL 情報量が関連するのは予想できるかもしれない．以下のような，もう少し明示的な関係性もあることが説明されている (Dabak & Johnson, 2002)．分布 p_0 と分布 p_1 を考え，パラメータ $t \in [0,\ 1]$ を考えた時，

$$KL\left(p_0; p_1\right) + KL\left(p_1; p_0\right) = \int_0^1 F(t)dt \qquad (6)$$

という関係がある．ただし，$F(t)$ は（p_0 と p_1 を結ぶ経路上の）t が表す点における F 情報量である．さらに

$$KL\left(p_0; p_1\right) = \int_0^1 tF(1-t)dt, \qquad (7)$$

$$KL\left(p_t; p_0\right) = \int_0^t uF(u)du \qquad (8)$$

という関係性も示されている．この式は，つまり KL 情報量は各点における F 情報量を足したような量になっていることを示している．また，$KL\left(p_t; p_0\right)$ に関しては，p_t に近づくほど u の値は大きくなるため，p_t に近づくほどより重みが付けられていると考えられる．例えば，モデル A を分布 p_0 が表すとし，モデル B を分布 p_1 が表すとすると，$KL\left(p_0; p_1\right)$ はモデル A が選ばれる確率に関係している．この $KL\left(p_0; p_1\right)$ は，モデル A を表す分布 p_0 周りの F 情報量を大きくすると，連動して大きくなりやすいことが予想される．逆に $KL\left(p_1; p_0\right)$ を大きくするには，モデル B を表す p_1 周りの F 情報量を大きくすると良い．つまり，あるモデルの F 情報量を大きくすると，そのモデルがモデル選択で選ばれやすくなると予想される．さらに，これは各モデルの F 情報量（あるいは F 情報行列の行列式）のコントラストに影響を受ける可能性も考えられる．式 (6) の両辺から $2KL\left(p_1; p_0\right)$，つまり $2KL(B; A)$ を引くと，コントラスト $KL(A; B) - KL(B; A)$ が大きいほど，全体の $\int_0^1 F(t)dt$ が大きくなると考えられる．式 (6) から $\int_0^1 F(t)dt$ を $KL(A; B)$，$KL(B; A)$ の二つで “分配” することになっている．また，モデル A の F 情報量が上がるのと同時に，モデル B の F 情報量が上がると，$KL(A; B)$ が上昇すると同時に $KL(B; A)$ が上昇しうる．そのため，$KL(A; B)$ を上げながら，$KL(B; A)$ は抑えてコントラストを大きくすることが，真のモデルがモデル A の時にモデル A を選びたい状況では重要となると予想できる．KL 情報量のコントラストを大きくすると，全体の $\int_0^1 F(t)dt$ も大きくなり $KL(A; B)$ の $KL(B; A)$ と比べた時の “取り分” も大きくなるからである．そして，上記の説明から F 情報量のモデル間のコントラストを大きくすることによって KL 情報量のコントラストも大きくなると予想される．そこで刺激選択基準として，各モデルの F 情報量の差分を最大化するという新たな手法も追加して，3 節では各刺激選択法におけるモデル選択のパフォーマンスを検討する．なお，KL 情報量を直接刺激選択基準とするのではなく，F 情報量をコントロールすることによって，KL 情報量やモデルリカバリ率をコントロールしようとしている．これは，著者の関心が，推定精度を最大化する CAT（のモデル選択への影響）から出ていることと，モデル選択と推定精度の関連を調べることにあることによる．

3. シミュレーション実験

本節のシミュレーション実験においては，3 つのモデルにおいてそれぞれ 2 つのシミュレーションを行う．2 つのシミュレーションとは第一に，F 情報量と KL 情報量の関係を経験的に確認することを目的として行う．モデル A の F 情報行列の行列式を FA，モデル B の F 情報行列の行列式を FB，その差分を FA-FB，特定のパラメータ値におけるモデル A からモデル B への KL 情報量（$KL(A; B)$）を KLA，モデル B からモデル A への KL 情報量を KLB，その差分を KLA-KLB と今後は略記する．第一のシミュレーションでは，FA，FB，FA-FB，KLA，KLB，KLA-KLB の相関を確認する．第二に，FA，FB，FA-FB，FB-FA それぞれを最大化するような刺激選択間で，モデル選択のパフォーマンスを比較する．つまり F 情報量を刺激デザインによってコントロールすることで，モデル選択のパフォーマンスをコントロールできるかを確認する．本研究で使用した R コードは Open Science Framework（OSF: https://osf.io/p79ea/）にて公開している．

3.1. 遅延価値割引モデル

3.1.1. シミュレーション 1

3.1.1.1 モデル

3.1 節のシミュレーション実験では遅延価値割引モデル (Ahn et al., 2020; Madden et al., 2003; Odum, 2011; Shamosh & Gray, 2008) というモデルを例として検討する．遅延価値割引（以降，Delay discounting, DD）課題では，参加者が少額の即時報酬を，多額の遅延報酬に比べどれくらい好むかを測定する．DD モデルでは，このような衝動性のようなものを測ることが関心となることが多い．そのため，DD 課題では例えば，すぐにもらえる 5 千円と 1 カ月後にもらえる 1 万円のどちらが良いかを意思決定してもらう．一方は即時報酬（遅延時間 0）でもう一方は遅延報酬であることがほとんどである．

$A_{ij}^{(s)}$，$A_{ij}^{(d)}$ をそれぞれ参加者 i の試行 j における即時報酬がもらえる選択肢，遅延報酬がもらえる選択肢，$x_{ij}^{(s)}$，$x_{ij}^{(d)}$ を参加者 i の試行 j における即時報酬，遅延報酬額，$time_{ij}$ を参加者 i の試行 j における遅延時間とする．この実験課題における実験刺激は $(x_{ij}^{(s)},\ x_{ij}^{(d)},\ time_{ij})$ の 3 次元である．

DD モデルでは，

$$y_{ij} \sim Bernoulli\left(p\left(y_{ij}=1;\boldsymbol{\theta_i}\right)\right), \tag{9}$$

$$p\left(y_{ij}=1;\boldsymbol{\theta_i}\right) = logit^{-1}\left\{\beta_i\left(u\left(A_{ij}^{(s)}\right)-u\left(A_{ij}^{(d)}\right)\right)\right\}, \tag{10}$$

$$u\left(A_{ij}^{(s)}\right) = x_{ij}^{(s)} \tag{11}$$

というデータ生成モデルが仮定される．双曲線関数を仮定するモデルでは

$$u\left(A_{ij}^{(d)}\right) = \frac{x_{ij}^{(d)}}{1+k_i\ time_{ij}} \tag{12}$$

という関数系を仮定し，指数形を仮定するモデルでは

$$u\left(A_{ij}^{(d)}\right) = x_{ij}^{(d)} \exp\left(-k_i\ time_{ij}\right) \tag{13}$$

という関数系を仮定する．パラメータ k_i は割引率パラメータと呼ばれ，衝動性のような概念を表すとされる．以降，双曲線関数をモデル A，指数形の関数をモデル B と呼ぶ．一般に多くの 2 値意思決定モデルを仮定する場合の，F 情報行列の式は導出されている (Fujita et al, 2022) ため，本研究でもその式を利用する．

3.1.1.2 方法

一つ目のシミュレーションでは，単にデータ生成を行い，F 情報行列と KL 情報量を計算するという以下のシミュレーションの流れである．1. 試行数，パラメータ真値を決める．2. 離散一様分布からランダムに刺激を固定する．3. パラメータ真値を直接利用して，FA，FB，KLA，KLB を計算する．シミュレーションの設定については，試行数は 60 試行，真値は $k=0.2$，$\beta=1$，刺激候補は報酬額が $1, 2, \ldots, 20$，遅延時間が $1, 2, \ldots 10$ である．

3.1.1.3 結果と考察

FA，FB，FA-FB，KLA，KLB，および KLA-KLB の 6 変数に関する散布図を図 1，相関表を表 1 に示す．本研究の流れ上，最も重要な結果は，FA-FB と KLA-KLB が 0.6 程度の正の相関を持つという点である．つまり，モデル A の F 情報量（推定精度）がモデル B の F 情報量（推定精度）に比べ相対的に大きいほど，モデル A をモデル選択で選びやすくなると予想される．

個別に結果を見ていく．FA に関しては，FB と正の相関を持つ．つまり，モデル A の F 情報量（推定精度）を上げると，基本的にモデル B の F 情報量（推定精度）も上がるということを意味する．モデル A にとって良い刺激は，モデル B にとっても良いことが多いということである．KLA，KLB とは，ともに 0.6〜0.7 程度の正の相関を持ち，KLA との相関の方がやや大きい．また KLA-KLB は 0.3 程度の正の相関を持つ．FB に関しては，KLA，KLB とは，ともに 0.5〜0.7 程度の正の相関を持ち，KLB との相関の方がやや大きい．また KLA-KLB とは −0.3 程度の負の相関を持つ．つまり，FA，FB が上がると，ともに KLA，KLB を上昇させることになるが，その上昇量は（スケールを揃えれば）FA では KLA の方が相対的に大きく，FB では KLB の方が相対的に大きい．また FA-FB に関しては，KLA，KLB ともに −0.2〜−0.4 程度の負の相関を持ち，KLB との相関の方が絶対値が大きい．これは，モデル B の F 情報行列の行列式の方がスケールが大きい（表 2）ことが関係していると考えられる．KLA に関しては，KLB と 0.9 程度の正の相関を持つ．逆に言うと，KLA と KLB は高い相関を持つが，1 対 1 に完全に対応しているわけではない．

これらの結果から，例えば FA を上昇させると，FB

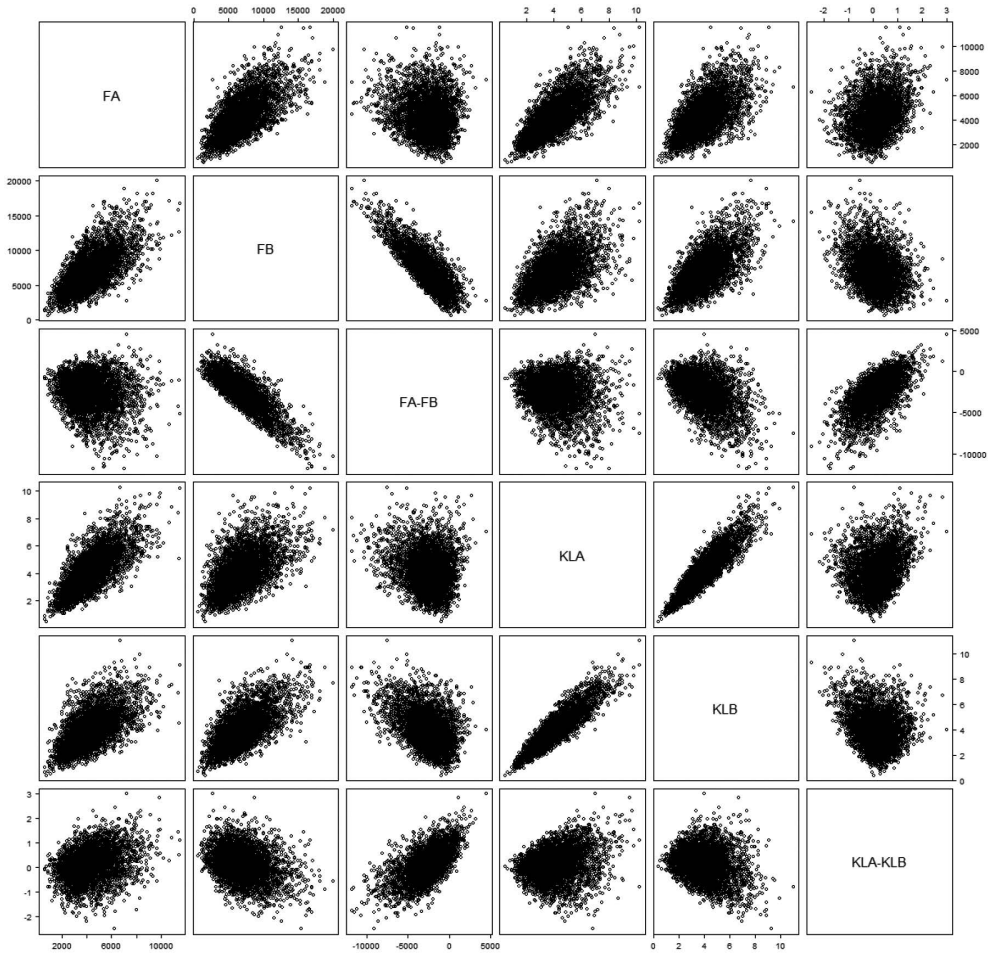


図 1. DD モデルにおける F 情報行列の行列式と KL 情報量の散布図
FA はモデル A の F 情報行列の行列式，FB はモデル B の F 情報行列の行列式，FA-FB は FA と FB の差分を表す．KLA はモデル A からモデル B への KL 情報量，KLB はモデル B からモデル A への KL 情報量，KLA-KLB は KLA と KLB の差分を表す．

や KLA，KLB も同時に上昇することが分かる．しかし，その上昇量は完全に 1 対 1 対応しているわけではなく，例えば FB を上げて FA を抑えれば，相対的に KLB が上がって KLA の上昇量は抑えることができると考えられる．それにより，モデル間での F 情報量（推定精度）や KL 情報量のコントラストが生まれ，モデル選択のパフォーマンスに影響を及ぼすと予想される．この結果を踏まえシミュレーション 2 では，従来の FA 最大化や FB 最大化を行う CAT に加え，FA-FB を最大化する刺激選択などを追加して，モデル選択のパフォーマンスを検討する．

3.1.2. シミュレーション 2

3.1.2.1 方法

シミュレーションの流れは以下の通りである．試行数, パラメータ真値, 真のモデルを固定する．推定のため初期 5 試行は刺激をランダムに選択する．その後, 1. 推定, 2. 刺激選択, 3. データ生成を繰り返す．全試行数分, 終わったのちに WAIC (渡辺, 2012) を計算し, モデル選択を行う．このシミュレーションを 200 回繰り返して，モデル A が選ばれた割合を計算した．シミュ

表 1. DD モデルにおける F 情報行列の行列式と KL 情報量の相関係数

	FA	FB	FA-FB	KLA	KLB	KLA-KLB
FA	1.000					
FB	0.678	1.000				
FA-FB	−0.148	−0.827	1.000			
KLA	0.734	0.541	−0.166	1.000		
KLB	0.603	0.674	−0.446	0.904	1.000	
KLA-KLB	0.304	−0.299	0.635	0.226	−0.212	1.000

Note. モデルは遅延価値割引モデル.

表 2. DD モデルにおける F 情報行列の行列式

		真のモデル			
		モデル A		モデル B	
		FA	FB	FA	FB
刺激選択法	random	2,136	20,375	102	968
	FA	100,622	393,374	47,849	188,212
	FB	89,373	542,786	29,903	214,165
	FA-FB	21,279	25,135	9,799	14,414
	FB-FA	86,619	549,151	25,795	211,335

Note. 列名における FA（FB）はモデル A（B）の F 情報行列の行列式を表す．行名における FA（FB）は FA（FB）最大化による刺激選択法を表す．モデルは遅延価値割引モデルである．モデル A が双曲線関数，モデル B が指数関数を利用したモデルである．

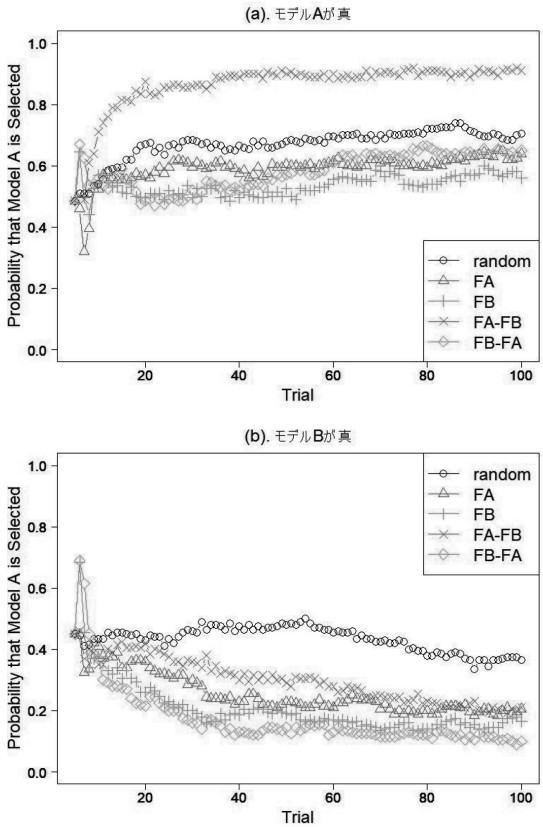


図 2. DD モデルにおけるモデルリカバリ率
試行ごと（横軸）のモデル選択結果（縦軸）の結果．図 2a が真のモデルがモデル A（双曲線関数）の時，図 2b が真のモデルがモデル B（指数関数）の時の結果.

レーションの設定は以下の通りである．試行数は 100 試行, 真のモデルはモデル A あるいはモデル B, 刺激候補値はシミュレーション 1 と同様である．パラメータ真値は $k \sim Beta(12.6,\ 50.4)$, $\beta \sim Beta(12,\ 12) * 2$ とした．k は平均=0.2, sd=0.05, β は平均=1, sd=0.2 という設定である．刺激選択条件は以下の 5 条件を設定した．ランダム選択条件：離散一様分布からランダムに刺激を選択する．; FA 条件：モデル A の F 情報行列の行列式（FA）を最大化する刺激を選択する．モデル A を仮定した従来の CAT である．; FB 条件：FB を最大化する刺激を選択する．; FA-FB 条件：モデル A の F 情報行列の行列式 – モデル B の F 情報行列の行列式を最大化する刺激を選択する．; FB-FA 条件：FB – FA を最大化する刺激を選択する．

3.1.2.2 結果と考察

各刺激選択条件ごとの，モデル A が選ばれる確率の結果を図 2 に示す．図 2a は真のモデルがモデル A の結果，図 2b は真のモデルがモデル B の結果を示す．まず真のモデルがモデル A の結果を見る．最もモデ

ル選択のパフォーマンスが良いのは，FA-FB 条件である．つまりモデル A の F 情報量（推定精度） を上げてモデル B の F 情報量（推定精度）を抑えることで，モデル選択のパフォーマンスは良くなる．パフォーマンスが最も悪いのは，FB 最大化と FB-FA 最大化条件である．つまり，モデル B の F 情報量を上げてしまうと，真のモデルがモデル A の状況でも，モデル B を五分五分程度の確率で選んでしまう．ただし FB-FA 条件は 50 試行あたりからは FA 条件と同等程度にはなっている．また，FA 最大化条件は，モデル選択のパフォーマンスは 0.6 程度とそれほど向上しない．この原因を検討するため，各モデルの F 情報行列の行列式を算出したのが，表 2 である．今回のモデルでは，FB の方が FA よりスケールが 10 倍弱程度大きいことが分かる．つまり，FA を最大化する刺激を使用することで，同時に FB も上昇し，かつ FB の方が上昇のスピードが速いために，モデル B を選択しやすくなってしまったという可能性がある．またランダム選択条件は，FA 条件よりモデルリカバリ率は高かった．原因の一つとしては，FB （モデル B の推定精度）が上がらないことによって，モデル B が選ばれやすくなるという傾向を回避できた可能性が考えられる．

次に真のモデルがモデル B の結果を確認する（図 2b）．まず最も素早くモデル選択のパフォーマンスが良くなっているのは，FB，FB-FA 最大化条件である．つまり，FB を大きくすることで，モデル B は選ばれやすくなる．ランダム刺激選択は，モデル選択のパフォーマンスとしては，相対的に低い結果となった．解釈がやや難しいのは，FA 条件，FA-FB 条件と FB 条件のパフォーマンスが 100 試行付近では同等であることである．一方で，20 から 40 試行付近でモデルリカバリ率の向上が FA-FB 条件で遅く，次に FA 条件で遅いという結果も見られた．これは，モデル B の行列式の方が大きくなりやすいため，FA 条件などでも FB 条件と最終的には同等のパフォーマンスとなったと考えられる．当初の予測では FA-FB 条件はモデル B の選択確率は上がらないというものであったが，モデル B のペナルティをあまりにも重視することによって，モデル A の F 情報量（推定精度）が上がりにくいことにより，モデル A を選びにくくなった可能性が考えられる．なお付録において，推定の良さについて議論している．具体的には刺激条件ごとに，パラメータ真値と推定値のズレの指標として RMSE（Root mean squared error）を確認している．

3.2. 累積プロスペクト理論

3.2.1. シミュレーション 1

3.2.1.1 モデル

3.2 節では累積プロスペクト理論 (CPT; Tversky & Kahneman, 1992) モデルを例として 3.1 節と同様のシミュレーション実験を行う．意思決定課題については，選択肢 A_{ij} においては，確率 $p_{ij1}^{(A)}$ で報酬 $x_{ij1}^{(A)}$ がもらえ確率 1-$p_{ij1}^{(A)}$ で報酬 $x_{ij2}^{(A)}$ がもらえるクジを考える (Lauriola et al., 2007; Nilsson et al., 2011)．選択肢 B_{ij} も同様の構造であるが，本研究では選択肢 B の確率 $p_{ij1}^{(B)}$ は不明である状況を扱う．参加者には試行間で確率 $p_{ij1}^{(A)}$ は異なるが，選択肢 B の確率は常に一定であると教示する．興味の一つは，選択肢 B における $p_{ij1}^{(B)}$ に対する主観的な確率判断である．今後は選択肢 A，B で共通の事項については (A) や (B) という表記は省略することがある．

この意思決定課題での反応をモデル化するために，Tversky and Kahneman (1979) はプロスペクト理論（Prospect Theory; PT）を提案した．PT モデルでは選択肢 A の価値は

$$V\left(A_{ij}\right) = v\left(x_{ij1}\right) w\left(p_{ij1}\right) + v\left(x_{ij2}\right) w\left(1 - p_{ij1}\right) \tag{14}$$

で計算されると仮定する．ただし，$v(\cdot)$ は報酬を主観的な価値に変換する価値関数であり，$w(\cdot)$ は確率値を意思決定の重みに変換する確率加重関数である．Tversky and Kahneman (1992) ではそれぞれ，利得（i.e., 報酬額が非負の）状況において

$$v\left(x_{ijk}\right) = x_{ijk}^{\alpha_i}, \tag{15}$$

$$w\left(p_{ij1}\right) = \frac{p_{ij1}^{\gamma_i}}{\left\{p_{ij1}^{\gamma_i} + \left(1 - p_{ij1}\right)^{\gamma_i}\right\}^{\frac{1}{\gamma_i}}} \tag{16}$$

という関数形を提案した．α_i $(0 \leq \alpha_i \leq 1)$，γ_i $(0 \leq \gamma_i)$ はパラメータである．本研究では選択肢 B での確率が不明であるため，Abdellaoui et al. (2005) を参考にして，

$$w\left(\theta_{i1}\right) = \frac{\theta_{i1}^{\gamma_i}}{\left\{\theta_{i1}^{\gamma_i} + \left(1 - \theta_{i1}\right)^{\gamma_i}\right\}^{\frac{1}{\gamma_i}}} \tag{17}$$

を仮定する．ただし θ_{i1} は参加者 i の主観確率を表すパラメータである．

意思決定データに対しては DD モデルと同様の構造である．つまり，

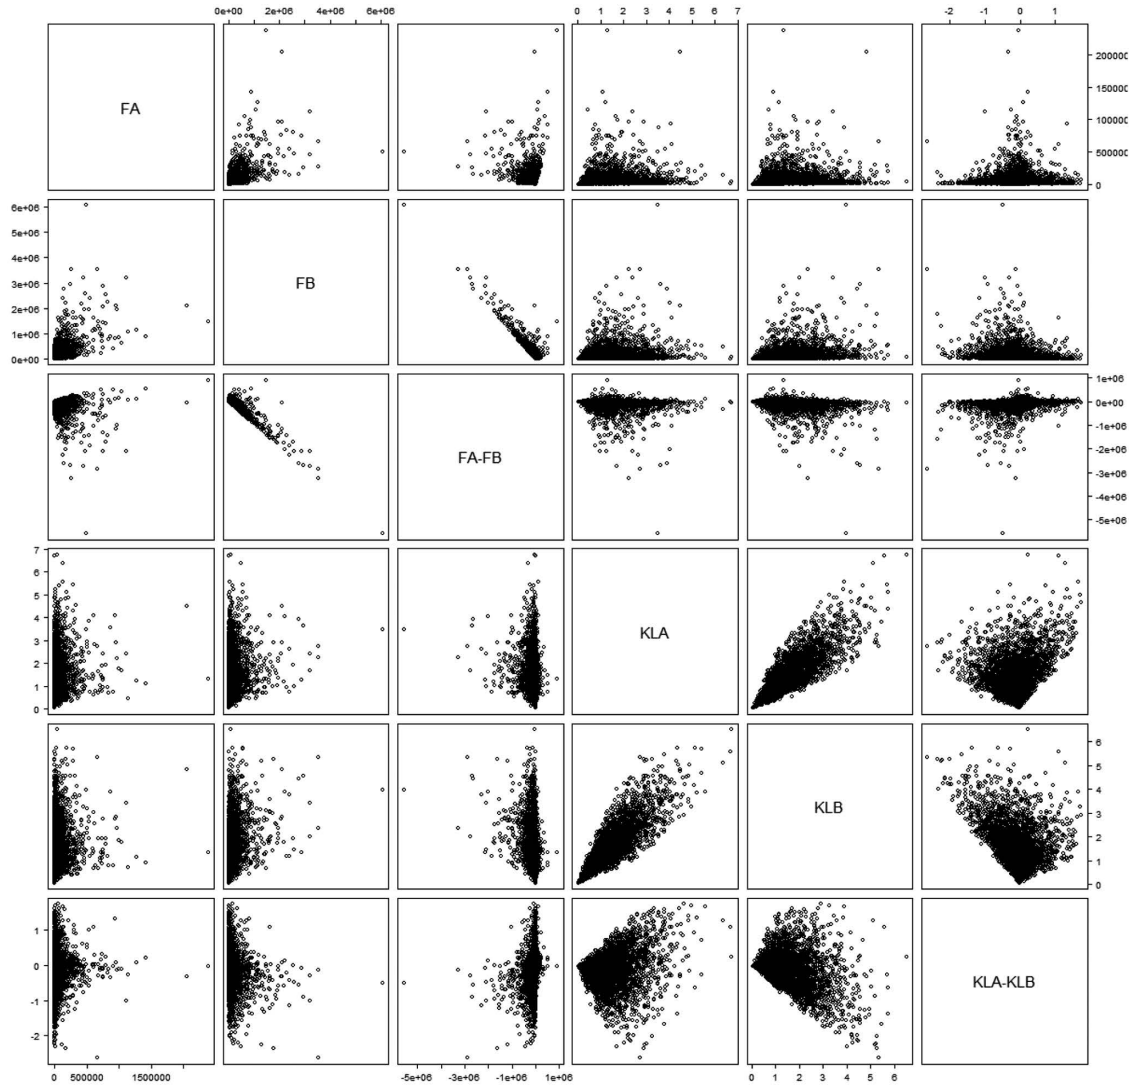


図 3. CPT モデル，PT モデルにおける F 情報行列の行列式と KL 情報量の散布図
FA，KLA などの意味は図 1 と同様．モデルは CPT モデルと PT モデル．

$$y_{ij} \sim Bernoulli\left(p\left(y_{ij}=1;\boldsymbol{\zeta_i}\right)\right), \quad (18)$$

$$p\left(y_{ij}=1;\boldsymbol{\zeta_i}\right) = logit^{-1}\left\{\phi_i\left(V\left(A_{ij}\right)-V\left(B_{ij}\right)\right)\right\} \quad (19)$$

を仮定する．ただし $\boldsymbol{\zeta_i}=(\theta_i,\gamma_i,\alpha_i,\phi_i)$ である．

PT モデルの拡張として CPT モデルも提案されている (Tversky & Kahneman, 1992)．CPT モデルでは

$$V\left(A_{ij}\right) = v\left(x_{ij1}\right)w\left(p_{ij1}\right) + v\left(x_{ij2}\right)\left(1-w\left(p_{ij1}\right)\right) \quad (20)$$

と仮定される．PT モデルでの第二項部分は $w(1-p_{ij1})$ だったが，CPT モデルでは $(1-w\left(p_{ij1}\right))$ となっている．以降，CPT モデルをモデル A，PT モデルをモデル B と呼ぶ．

表 3. CPT モデル，PT モデルにおける F 情報行列の行列式と KL 情報量の相関係数

	FA	FB	FA-FB	KLA	KLB	KLA-KLB
FA	1.000	0.624	−0.291	0.207	0.180	0.034
FB	0.624	1.000	−0.929	0.259	0.329	−0.172
FA-FB	−0.291	−0.929	1.000	−0.219	−0.318	0.227
KLA	0.207	0.259	−0.219	1.000	0.879	0.151
KLB	0.180	0.329	−0.318	0.879	1.000	−0.340
KLA-KLB	0.034	−0.172	0.227	0.151	−0.340	1.000

Note. モデルは累積プロスペクト理論（CPT）モデル（モデル A）あるいはプロスペクト理論（PT）モデル（モデル B）.

3.2.1.2 方法

シミュレーションの流れは 3.1.1.2 節と同様である．試行数は 30 試行，パラメータ真値は $\theta = 0.5$, $\gamma = 0.6$, $\alpha = 0.8$, $\phi = 1$ とした．刺激候補は報酬額については 10, 15, . . . , 100，報酬確率については 0.01 から 0.99 を等分する 16 個の点であった．

3.2.1.3 結果と考察

FA，FB，FA-FB，KLA，KLB，および KLA-KLB に関する散布図を図 3，相関表を表 3 に示す．結果は数値自体に違いはあるが，DD モデルの場合と同様の傾向であった．つまり，FA-FB と KLA-KLB は，絶対値は表 1 と比べると小さいが，0.2 程度の正の相関を持つ．FA は，FB，KLA，KLB と正の相関を持ち，FA と KLA との相関の方が FA と KLB との相関よりもやや大きい．FB は FB と KLB との相関の方が FB と KLA との相関よりも大きい．FA-FB は KLA，KLB と負の相関を持ち，絶対値は KLB との相関の方が大きい．

3.2.2. シミュレーション 2

3.2.2.1 方法

シミュレーションの流れは 3.1.2.1 節と同様である．試行数は 50 試行，刺激候補値は 3.2.1 節と同様，真のモデルはモデル A あるいはモデル B，パラメータ真値は $\theta \sim Beta(12,\ 12)$, $\gamma \sim Beta(57,\ 38)$, $\alpha \sim Beta(50.4,\ 12.6)$, $\phi \sim Beta(5.05,\ 5.05) * 2$ であった．パラメータ真値は，θ は平均=0.5, sd=0.1, γ は平均=0.6, sd=0.05，α は平均=0.8, sd=0.05，ϕ は平均=1, sd=0.3 となるように設定した．刺激選択条件は DD モデルのものと同様である．ただし，計算負荷を下げるため，CAT を行う条件においても，$x_{ij1}^{(A)}$, $x_{ij2}^{(B)}$ は離散一様分布からランダムに選択した．つまり，F 情報量を基準に刺激選択するのは $x_{ij2}^{(A)}$, $p_{ij1}^{(A)}$, $x_{ij1}^{(B)}$ の 3 次元分のみである．

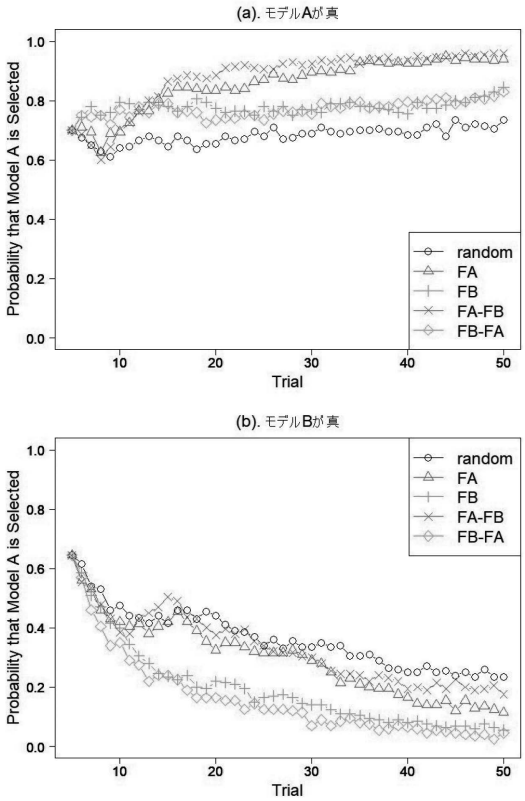


図 4. CPT モデル，PT モデルにおけるモデルリカバリ率 試行ごと（横軸）のモデル選択結果（縦軸）の結果．図 4a が真のモデルがモデル A（CPT モデル）の時，図 4b が真のモデルがモデル B（PT モデル）の時の結果．

3.2.2.2 結果と考察

各刺激選択条件ごとの，モデル A が選ばれる確率の

表 4. CPT モデル，PT モデルにおける F 情報行列の行列式

		真のモデル			
		モデル A		モデル B	
		FA	FB	FA	FB
刺激選択法	random	31,541	47,048	27,795	68,283
	FA	16,410,010,146	43,265,134	5,951,293,959	524,342,196
	FB	966,099,044	2,545,128,070	22,090,694	27,211,827,729
	FA-FB	7,290,165,841	14,229,761	15,486,674,507	327,486,139
	FB-FA	220,147,165	1,635,514,537	8,524,453	6,678,509,525

Note. モデルはモデル A が累積プロスペクト理論（CPT）モデル，モデル B がプロスペクト理論（PT）モデルを表す．

結果を図 4 に示す．図 4a は真のモデルがモデル A の結果，図 4b は真のモデルがモデル B の結果を示す．まず真のモデルがモデル A の結果を見る．最もモデル選択のパフォーマンスが良いのは，FA-FB，FA 条件である．次に，FB，FB-FA 条件が良く，ランダム選択条件が最も悪い．50 試行付近においては，F 情報量のコントラストがあるかどうかはそれほど影響していないが，20 から 30 試行付近では，FA 条件より FA-FB 条件の方がややパフォーマンスが良い部分がある．

次に真のモデルがモデル B の結果を確認する．最もモデル選択のパフォーマンスが良いのは，FB-FA，FB 条件である．次に FA，FA-FB 条件が良く，ランダム選択条件が最も悪い．FB-FA 条件と FB 条件は差はほとんどないが，FB-FA 条件が全体を通してややモデルリカバリ率が高い．また 50 試行付近では FA 条件は FA-FB 条件よりパフォーマンスがやや高い．なお，それぞれのモデルの行列式のスケールは表 4 に示す．スケールはモデル間で一貫した違いはほとんどなく，刺激選択条件に依存していた．

3.3. 累積プロスペクト理論：確率加重関数の変更

3.3.1. シミュレーション 1

3.3.1.1 モデル

CPT モデルにおいて，確率加重関数 $w(\cdot)$ は Tversky and Kahneman (1992) の提案した形の他に

$$w\left(p_{ij1}\right) = \exp\left(-\left(-\log\left(p_{ij1}\right)\right)^{\gamma_i}\right) \qquad (21)$$

という形も Prelec (1998) により提案されている．本節では，Tversky and Kahneman (1992) の確率加重関数を仮定するモデルをモデル A，Prelec (1998) の確率加重関数を仮定するモデルをモデル B と呼ぶ．

3.3.1.2 方法

シミュレーションの流れは 3.2.1.2 節と同様である．また，試行数（30），パラメータ真値（$\theta = 0.5$, $\gamma = 0.6$, $\alpha = 0.8$, $\phi = 1$），刺激候補値も 3.2.1.2 節と同様である．

3.3.1.3 結果と考察

FA，FB，FA-FB，KLA，KLB，および KLA-KLB に関する散布図を図 5，相関表を表 5 に示す．結果は 3.1 節，3.2 節のものとほぼ同様であった．つまり，FA-FB は KLA-KLB と 0.25 程度の正の相関があった．また FA は FB，KLA，KLB と相関し，KLA との相関が KLB との相関より数値上は大きかった．ただし，FA および FB に関して，KLA との相関と KLB との相関の差分は，それほど顕著ではなかった．KLA と KLB の相関は 0.98 程度と非常に高い値であった．

3.3.2. シミュレーション 2

3.3.2.1 方法

シミュレーションの流れ，試行数，刺激候補値，パラメータ真値，刺激選択条件は全て 3.2.2 節と同様である．ただし，真のモデルはモデル A（Tversky and Kahneman (1992) のモデル）あるいはモデル B（Prelec (1998) のモデル）である．

3.3.2.2 結果と考察

各刺激選択条件ごとの，モデル A が選ばれる確率の結果を図 6 に示す．図 6a は真のモデルがモデル A の結果，図 6b は真のモデルがモデル B の結果を示す．まず真のモデルがモデル A の結果を見る．最もモデル選択のパフォーマンスが良いのは，FA-FB 条件で，次に FA 条件，FB 条件，FB-FA 条件，ランダム選択条件であった．つまり，FA を上げて FB を抑えるこ

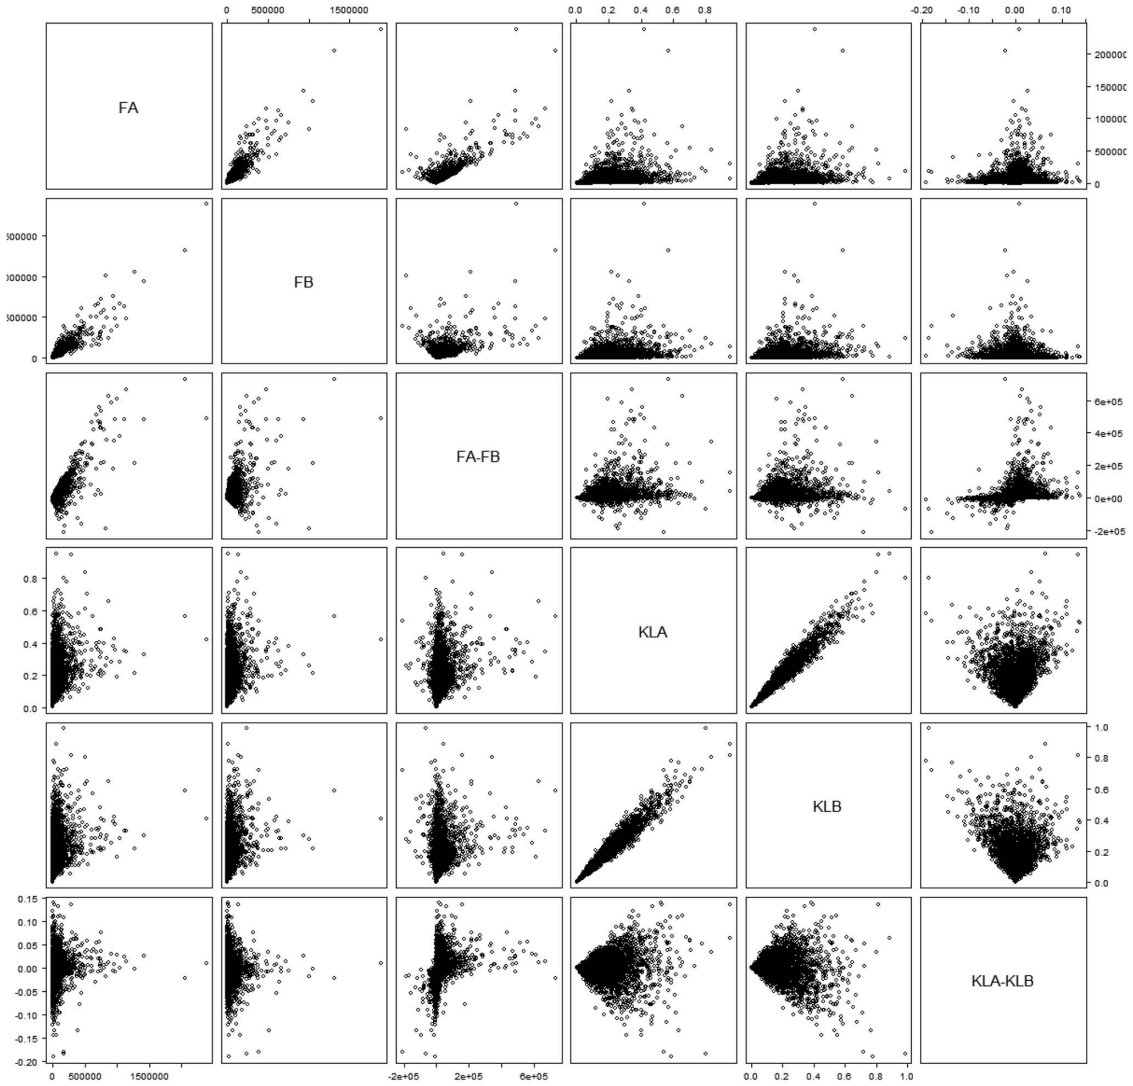


図 5. 確率加重関数を変化させた CPT モデルにおける F 情報行列の行列式と KL 情報量の散布図
FA，KLA などの意味は図 1 と同様．モデルは Tversky and Kahneman (1992) のモデルと，Prelec (1998) のモデルである．

とにより，モデル A を選択する確率を高めることができると考えられる．

次に真のモデルがモデル B の結果を確認する．最もモデル選択のパフォーマンスが良いのは，FB-FA 条件，次に FB 条件が良く，その次に FA 条件，ランダム選択条件，最も悪いのが FA-FB 条件であった．これも，FB を上げて FA を抑えることにより，モデル B を選択する確率を高めることができることを示す．興味深いことは，真のモデルを仮定する従来の CAT（図 6a では FA 条件，図 6b では FB 条件）は，モデル選択の観点からは最良の刺激選択法ではないことである．なお行列式のスケールについては表 6 に示す．ややモデル A のスケールが大きいように見える部分もあるが，基本的に一貫して 2 倍以上違うなどの大き

表 5. 確率加重関数を変化させた CPT モデルにおける F 情報行列の行列式と KL 情報量の相関係数

	FA	FB	FA-FB	KLA	KLB	KLA-KLB
FA	1.000	0.922	0.822	0.393	0.375	0.076
FB	0.922	1.000	0.537	0.361	0.374	−0.074
FA-FB	0.822	0.537	1.000	0.324	0.265	0.273
KLA	0.393	0.361	0.324	1.000	0.978	0.074
KLB	0.375	0.374	0.265	0.978	1.000	−0.135
KLA-KLB	0.076	−0.074	0.273	0.074	−0.135	1.000

Note. モデルは Tversky and Kahneman (1992) のモデル（モデル A）あるいは Prelec (1998) のモデル（モデル B）である．

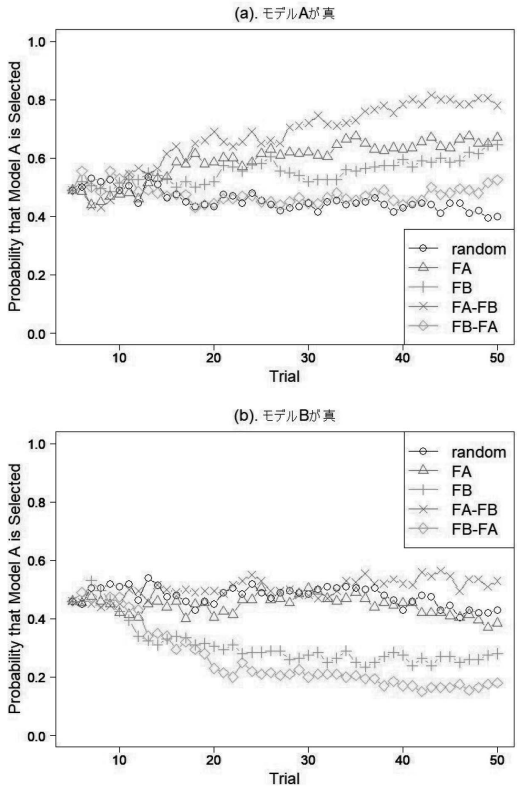


図 6. 確率加重関数を変化させた CPT モデルにおけるモデルリカバリ率
試行ごと（横軸）のモデル選択結果（縦軸）の結果．図 6a が真のモデルがモデル A（Tversky and Kahneman (1992) のモデル）の時，図 6b が真のモデルがモデル B（Prelec (1998) のモデル）の時の結果．

な違いはなく刺激選択条件によって変わる．

4. 総 合 考 察

4.1. 考察

本研究では，推定精度とモデル選択の関係，F 情報量と KL 情報量の関係について検討し，また推定精度の観点からの刺激選択により，モデル選択のパフォーマンスをコントロールできるかを検証した．

F 情報量と KL 情報量の関係については，先行研究において導出されている数式を説明し，そこから予測された，一方の F 情報量を上げると，そのモデルから別のモデルへの KL 情報量が上昇するという関係を経験的に確認した．またなぜ，そしてどのように F 情報量を基準とする CAT が，モデル選択のパフォーマンスに影響するかも説明した．シミュレーション 2 では，刺激選択で F 情報量をコントロールすることによって，モデル選択のパフォーマンスが変化することを確認した．CPT モデルを使用した先行研究 (Fujita and Okada, 2022) と同様に，基本的にあるモデルの F 情報量を CAT により上げると，そのモデルが選ばれやすくなることを確認した．また，F 情報量のモデル間でのコントラストが重要となる場面があることも示した．

本研究から指摘される問題は，実験の組み方によって，モデル選択のパフォーマンスは，良い方向にも悪い方向にもコントロールできてしまうという点である．モデル選択のパフォーマンスが悪い方向に（無意識的にせよ意識的にせよ）動いてしまう例を 2 つあげる．例えば，モデル B を真だと主張したい研究者が実験を組む際には，モデル B に対するより豊富な知識や経験，関心がゆえに，モデル B の推定精度を適切に向上させる実験を組めてしまう可能性が高い．それゆえに，モデル A とモデル B の間でモデル選択をすると

表 6. 確率加重関数を変化させた CPT モデルにおける F 情報行列の行列式

		真のモデル			
		モデル A		モデル B	
		FA	FB	FA	FB
刺激選択法	random	29,880	17,192	44,462	26,810
	FA	16,410,010,146	542,875,525	37,545,455,388	2,625,826,044
	FB	3,198,793,483	2,397,017,339	2,733,682,645	7,890,355,393
	FA-FB	14,611,910,895	435,036,658	68,759,593,248	2,057,055,458
	FB-FA	651,290,418	1,667,497,060	921,061,986	7,726,270,110

Note. モデルはモデル A が Tversky and Kahneman (1992) のモデル，モデル B が Prelec (1998) のモデルを表す．

きに，モデル B の推定精度が相対的に高くなり，モデル選択でモデル B が選ばれやすくなるという偏りが生じてしまうかもしれない．つまり，知識や経験，関心がゆえに，主張したい方のモデルを選びやすくなるような実験を（無意識的に）組んでしまう可能性がある．2 つ目の例が，先行研究の実験課題構造や実験刺激を踏襲する場合である．先行研究の課題自体が，モデル A よりモデル B に対して適切であり，モデル B の推定精度が相対的に高い場合には，モデル B を選びやすくなってしまう．仮にモデル A が真のモデルであった場合には，漸近的にはモデル A を選ぶ確率が高くなるだろうが，真のモデルが A であるという結論に到達するためには，無駄にデータ収集コストが多くかかってしまう危険性がある．例えば，本研究で使用したモデルでも 3.1 節と 3.3 節のモデルでは，モデル A が真である状況でも，刺激選択条件に依ってはモデル B を選ぶ確率を 50% 程度に保つことができてしまう．

そのためモデル選択のパフォーマンス（モデルリカバリ率）や実験デザインの評価を行えるようになる必要がある．今回の例（3.1 節）のように，モデル A とモデル B の F 情報量のスケールやモデルリカバリ率が非対称な場合もあるので，モデルリカバリ率を事前に確認することは当然重要である．それに加えて，実験デザインがどれかのモデルを相対的に好みやすい偏りのあるデザインになっていないか，という点を客観的な統計的量で検討しておくことが重要となる．実験デザインを適切に評価し，モデル選択や推定精度，検定の意味で，より適切な実験の下でデータ収集を行いたいからである．

モデル選択と推定精度の関係は興味深いものであった．つまり，推定精度を最大化しても，モデル選択のパフォーマンスは最適化されたことにはならないという関係性が理論的に予測される．実際に，FA-FB, FB-FA 条件はモデル選択のパフォーマンスは優れてるが，推定精度は最良とは限らないことが付録において示された．推定精度と検出力の関係は，推定精度を上げると検出力も上がるという関係であるが，モデル選択との関係はそれほど単純なものではなかった．より厳密に言うと，誤ったモデルの F 情報量（推定精度）を上げてしまうと，モデル選択で誤ったモデルが選ばれやすくなり，モデル選択のパフォーマンスは低下してしまう．つまり，刺激選択を考える際には，モデル選択と推定精度（検出力）のバランスを考える必要がある．実験の初期段階から特定のモデルの推定精度を最大化していると，モデル選択のパフォーマンスが低下したりモデルの重みが偏ってしまう危険性が生じうる．実験実施前に全ての刺激を決定する fixed design においても同様に，検出力最大化とモデル選択のパフォーマンス最大化は相いれないことになる．例えば，モデル選択をしてから，選ばれたモデルを仮定して検定（あるいは推定）を行う研究において，モデル選択を間違えないことと，（各モデル上での）検出力を最大化するという 2 つのバランスを考えることが重要となる．

4.2. 今後の展望，限界

本研究の限界について 2 点指摘しておく．1 点目は，理論的な説明，特にシミュレーション 1 に関してである．例えば，シミュレーション 1 では KL 情報量の計算などに，パラメータ真値を使用している．$KL(A, B)$ を計算したい場合は，モデル B のパラメータ値は本来モデル A のパラメータ真値ではなく，モデ

ル B のモデル A との KL 擬距離が最小になる点におけるパラメータ値を使用するのが概念的に正しいはずである．あるいは，シミュレーション 1 においては，真のモデルを仮定しデータ生成を行い，そのデータから得られた推定値を利用して F 情報量を計算することも考えられる．このようなシミュレーションのやり方もありうる．本研究では検討すべき要因を減らすために，パラメータ真値を直接利用して F 情報量等を計算した．また本論文では，KLA はモデル A が真である時のモデル A の選択確率に影響し，KLA-KLB のコントラストが重要として，FA-FB と KLA-KLB の関連やモデル選択との関連を検討している．しかし，KLA-KLB は，（モデル A が真の時に）モデル A が選ばれる確率には厳密には理論的に対応していない．KLB は真のモデルがモデル B の状況での量であるからである．もちろん，FA-FB と KLA-KLB が相関するという現象自体は興味深いし，KLA-KLB は（2.2 節で説明したように KLA の “取り分” を増やすという意味で）間接的にはモデル選択のパフォーマンスに影響すると予想できるが，真のモデルに関わらずモデル A が選択される確率において直接的関係という意味で KLA-KLB を指標とすることに高い妥当性があると考えているわけではない．そもそも著者の知る限り，KL 情報量からモデルリカバリ率を計算，予測できる解析的な式は不明である．

2 点目は，最適な実験デザインの設計法についてである．本論文の目的は，F 情報量と KL 情報量の関係を明らかにすることや，実験の組み方によってはモデル選択のパフォーマンスが（悪い方向に）コントロールできてしまうという問題を提起することであった．その具体的な解決策については，今後の課題として残る．つまり，具体的にどうやって刺激選択すると良いのか，モデル選択のパフォーマンスと検出力（あるいは推定精度）を同時にバランスよく向上させていくにはどのようにするか，という方法に関する議論は今後行われるべきである．

本研究では F 情報量と KL 情報量の関連，推定精度（や検出力）とモデル選択の関連を検討した．本来，統計理論としても実践的にも重要なトピックであるはずだが，著者の知る限り少なくとも心理統計学においては，たくさんの知見が蓄積されている領域ではない．今後は，本研究で扱ったような領域における，理論的な理解も深めていくべきだろう．

謝　　辞

本研究は JSPS 科研費 1920J22350 の助成を受けたものである．

参 考 文 献

Abdellaoui, M., Vossmann, F., & Weber, M. (2005). Choice-based elicitation and decomposition of decision weights for gains and losses under uncertainty. *Management Science*, **51**, 1384–1399. https://doi.org/10.1287/mnsc.1050.0388

Ahn, W. Y., Gu, H., Shen, Y., Haines, N., Hahn, H. A., Teater, J. E., Myung, J. I., & Pitt, M. A. (2020). Rapid, precise, and reliable measurement of delay discounting using a Bayesian learning algorithm. *Scientific Reports*, 1–10. https://doi.org/10.1038/s41598-020-68587-x

甘利俊一 (2014). 新版情報幾何学の新展開　サイエンス社.

甘利俊一・長岡浩司 (1993). 情報幾何の方法 岩波講座応用数学 [対象 12]. 岩波書店.

Bak, J. H., & Pillow, J. W. (2018). Adaptive stimulus selection for multi-alternative psychometric functions with lapses. *Journal of Vision*, **18**, 12, 1–25. https://doi.org/10.1167/18.12.4

Cavagnaro, D. R., Gonzalez, R., Myung, J. I., & Pitt, M. A. (2013). Optimal decision stimuli for risky choice experiments: An adaptive approach. *Management Science*, **59**, 2, 358–375. https://doi.org/10.1287/mnsc.1120.1558

Cavagnaro, D. R., Myung, J. I., Pitt, M. A., & Kujala, J. V. (2010). Adaptive design optimization: A mutual information-based approach to model discrimination in cognitive science. *Neural Computation*, **22**, 4, 887–905. https://doi.org/10.1162/neco.2009.02-09-959

Cavagnaro, D. R., Pitt, M. A., Gonzalez, R., & Myung, J. I. (2013). Discriminating among probability weighting functions using adaptive design optimization. *Journal of Risk and Uncertainty*, **47**, 3, 255–289. https://doi.org/10.1007/s11166-013-9179-3

Chang, H. H. (2015). Psychometrics behind computerized adaptive testing. *Psychometrika*, **80**, 1, 1–20. https://doi.org/10.1007/s11336-014-9401-5

Dabak, A.G. & Johnson, D.H. (2002). Relations between Kullback-Leibler distance and Fisher information *Manscript*.

Daniel Kahneman, & Amos Tversky. (1992). Advances in prospect theory: Cumulative representation of uncertainty. *Journal of Risk and Uncertainty*, **5**, 297–323. http://psych.fullerton.edu/mbirnbaum/psych466/articles/tversky_kahneman

_jru_92.pdf
DiMattina, C. (2015). Fast adaptive estimation of multidimensional psychometric functions. *Journal of Vision*, **15**, 9, 1–20. https://doi.org/10.1167/15.9.5
藤岡敦 (2021). 入門情報幾何—統計的モデルをひもとく微分幾何学—. 共立出版.
Fujita, K. & Okada, K. (2022). *Adaptive optimal stimulus selection in cognitive models using a model averaging approach*. https://doi.org/10.31234/osf.io/snhkp.
Fujita, K., Okada, K., & Katahira, K. (2022). The Fisher information matrix: A tutorial for calculation for decision making models. https://doi.org/10.31234/osf.io/hdwut
藤原彰夫 (2015). 情報幾何学の基礎 数理情報科学シリーズ 29. 牧野書店.
Heck, D. W., & Erdfelder, E. (2019). Maximizing the Expected Information Gain of Cognitive Modeling via Design Optimization. *Computational Brain and Behavior*, **2**, 3–4, 202–209. https://doi.org/10.1007/s42113-019-00035-0
Hinne, M., Gronau, Q. F., van den Bergh, D., & Wagenmakers, E. J. (2020). A Conceptual Introduction to Bayesian Model Averaging. *Advances in Methods and Practices in Psychological Science*, **3**, 2, 200–215. https://doi.org/10.1177/2515245919898657
Hoeting, J. A., Madigan, D., Raftery, A. E., & Volinsky, C. T. (1999). Bayesian model averaging: A tutorial. *Statistical Science*, **14**, 4, 382–401. https://doi.org/10.1214/ss/1009212519
Kim, W., Pitt, M. A., Lu, Z. L., Steyvers, M., & Myung, J. I. (2014). A hierarchical adaptive approach to optimal experimental design. *Neural Computation*, **26**, 2465–2492. https://doi.org/10.1162/NECO_a_00654
小西貞則・北川源四郎 (2004). 情報量規準 シリーズ〈予測と発見の科学〉2. 朝倉書店.
Kontsevich, L. L., & Tyler, C. W. (1999). Bayesian adaptive estimation of psychometric slope and threshold. *Vision Research*, **39**, 16, 2729–2737. https://doi.org/10.1016/S0042-6989(98)00285-5
Kujala, J. V., & Lukka, T. J. (2006). Bayesian adaptive estimation: The next dimension. *Journal of Mathematical Psychology*, **50**, 4, 369–389. https://doi.org/10.1016/j.jmp.2005.12.005
Lakens, D. (2022). Sample Size Justification. *Collabra: Psychology*, **8**, 1, 1–32. https://doi.org/10.1525/collabra.33267
Lauriola, M., Levin, I. P., & Hart, S. S. (2007). Common and distinct factors in decision making under ambiguity and risk: A psychometric study of individual differences. *Organizational Behavior and Human Decision Processes*, **104**, 130–149. https://doi.org/10.1016/j.obhdp.2007.04.001
Lesmes, L. A., Lu, Z. L., Baek, J., Tran, N., Dosher, B. A., & Albright, T. D. (2015). Developing Bayesian adaptive methods for estimating sensitivity thresholds (d') in Yes-No and forced-choice tasks. *Frontiers in Psychology*, **6**, 1–24. https://doi.org/10.3389/fpsyg.2015.01070
Ly, A., Marsman, M., Verhagen, J., Grasman, R. P. P. P., & Wagenmakers, E. J. (2017). A tutorial on fisher information. *Journal of Mathematical Psychology*, **80**, 40–55. https://doi.org/10.1016/j.jmp.2017.05.006
Madden, G. J., Begotka, A. M., Raiff, B. R., & Kastern, L. L. (2003). Delay discounting of real and hypothetical rewards. *Experimental and Clinical Psychopharmacology*, **11**, 2, 139–145. https://doi.org/10.1037/1064-1297.11.2.139
Meijer, R. R., & Nering, M. L. (1999). Computerized adaptive testing: Overview and an example. *Applied Psychological Measurement*, **23**, 3, 187–194. https://doi.org/https://doi.org/10.1177/01466219922031310
Mulder, J., & Van Der Linden, W. J. (2009). Multidimensional adaptive testing with optimal design criteria for item selection. *Psychometrika*, **74**, 2, 273–296. https://doi.org/10.1007/s11336-008-9097-5
Murphy, R. O., & Brincke, R. H. W. (2018). Hierarchical Maximum Likelihood Parameter Estimation for Cumulative Prospect Theory: Improving the Reliability of Individual Risk Parameter Estimates. *Management Science*, **64**, 1, 308–326. https://doi.org/10.1287/mnsc.2016.2591
Myung, J. I., Cavagnaro, D. A., & Pitt, M. A. (2013). A tutorial on adaptive design optimization. *Journal of Mathematical Psychology*, **57**, 53–67. https://doi.org/10.1016/j.jmp.2013.05.005
Myung, J. I., & Pitt, M. A. (2009). Optimal experimental design for model discrimination. *Psychological Review*, **116**, 3, 499–518. https://doi.org/10.1037/a0016104
Nilsson, H., Rieskamp, J., & Wagenmakers, E. J. (2011). Hierarchical Bayesian parameter estimation for cumulative prospect theory. *Journal of Mathematical Psychology*, **55**, 84–93. https://doi.org/10.1016/j.jmp.2010.08.006
Odum, A. L. (2011). Delay discounting: Trait variable? *Behavioural Processes*, **87**, 1, 1–9. https://doi.org/10.1016/j.beproc.2011.02.007
Ogungbenro, K., & Aarons, L. (2008a). Optimisation of sampling windows design for population pharmacokinetic experiments. *Journal of Pharmacokinetics and Pharmacodynamics*, **35**, 4, 465–482. https:// doi.org/10.1007/s10928-008-9097-1
Ogungbenro, K., & Aarons, L. (2008b). Sample size calculations for population pharmacodynamic experiments involving repeated dichotomous ob-

servations. *Journal of Biopharmaceutical Statistics*, **18**, 6, 1212–1227. https://doi.org/10.1080/10543400802375845
Ogungbenro, K., & Aarons, L. (2010a). Sample size/power calculations for population pharmacodynamic experiments involving repeated-count measurements. *Journal of Biopharmaceutical Statistics*, **20**, 5, 1026–1042. https://doi.org/10.1080/10543401003619205
Ogungbenro, K., & Aarons, L. (2010b). Sample size/power calculations for repeated ordinal measurements in population pharmacodynamic experiments. *Journal of Pharmacokinetics and Pharmacodynamics*, **37**, 1, 67–83. https://doi.org/10.1007/s10928-009-9144-6
Prelec, D. (1998). The probability weighting function. *Econometrica*, **66**, 497–527. https://doi.org/10.2307/2998573
Schönbrodt, F. D., & Wagenmakers, E. J. (2018). Bayes factor design analysis: Planning for compelling evidence. *Psychonomic Bulletin and Review*, **25**, 1, 128–142. https://doi.org/10.3758/s13423-017-1230-y
Segall, D. O. (1996). Multidimensional adaptive testing. *Psychometrika*, **61**, 2, 331–354. https://doi.org/10.1007/BF02294343
Shamosh, N. A., & Gray, J. R. (2008). Delay discounting and intelligence: A meta-analysis. *Intelligence*, **36**, 4, 289–305. https://doi.org/10.1016/j.intell.2007.09.004
竹内啓・広津千尋・公文雅之・甘利俊一 (2003). 統計学の基礎Ⅱ—統計学の基礎概念を見直す—. 岩波書店.
Tversky, A. & Kahneman, D. (1979). Prospect theory: An analysis of decision under risk. *Econometrica*, **47**, 263–292. https://doi.org/0012-9682(197903)47:2<263:PTAAOD>2.0.CO;2-3
Tversky, A., & Kahneman, D. (1992). Advances in prospect theory: Cumulative representation of uncertainty. *Journal of Risk and Uncertainty*, **5**, 297–323.
van der Linden, W.J. (2018). Adaptive testing. In: W. J. van der Linden (Ed). *Handbook of item response theory, volume three: application.* (pp.197–228). Boca Raton, FL: CRC Press. https:// doi.org/10.1201/9781315119144
Wasserman, L. (2000). Bayesian Model Selection and Model Averaging. *Journal of Mathematical Psychology*, **44**, 1, 92–107.
渡辺澄夫 (2012). ベイズ統計の理論と方法. コロナ社.
Weiss, D. J., & Kingsbury, G. G. (1984). Application of Computerized Adaptive Testing to educational problems. *Journal of Educational Measurement*, **21**, 4, 361–375. https://doi.org/10.1111/j.1745-3984.1984.tb01040.x
Zhang, S., & Lee, M. D. (2010). Optimal experimental design for a class of bandit problems. *Journal of Mathematical Psychology*, **54**, 6, 499–508. https://doi.org/10.1016/j.jmp.2010.08.002

（2022年12月26日受理，2023年7月27日採択）
（この間審査2回・審査期間合計99日）

付　　録

ここでは，3.1節のDDモデル，3.2節のCPTモデルとPTモデル，3.3節の確率加重関数を変えたCPTモデルの3つのシミュレーションにおける刺激選択条件ごとの推定の良さについて検討する．シミュレーション2においては，モデル選択結果のみを見たが，本付録においては，パラメータの真値と推定値のズレについて検討する．

シミュレーションの流れはCATを行うシミュレーション2と同様で，検討する指標がモデル選択結果ではなく，RMSEとなる．図2などと同様，真のモデルごとに作図した．さらに，推定時に仮定したモデル（2条件）ごとに作図する必要がある．またパラメータはDDモデルは2つ，CPTモデル等は4つ存在する．これら全ての結果を載せることはせず，DDモデルでは割引率k，CPTモデル等では確率加重関数に関わるパラメータγの結果を示す．これは，心理学的な関心上，kやγに着目することが多いこと，これらのパラメータは提示刺激により推定精度が増減しやすいことによる．

3.1節のDDモデルにおける結果を示したのが図A1である．真のモデルと推定時に仮定したモデルが異なっている状況は解釈が難しいため，基本的には真のモデルで推定した時の結果を説明する．真のモデルがモデルAの時における，モデルAでの割引率kのRMSEも，真のモデルがモデルBの時における，モデルBでの割引率kのRMSEも，FA-FB条件で高く推定のパフォーマンスが悪い．これはおそらく，モデルBのF情報量が大きくなるペナルティを考慮しすぎることで，全体的に良い刺激が選択できなかったと考えられる．モデルBのF情報量のスケールの方が相対的に大きいからである．特にモデルAが真の場合は，モデル選択のパフォーマンスではFA-FB条件が最も良いが，推定のパフォーマンスではFA-FB条件は最良ではないことが確認できた．

3.2節のモデルにおける結果を示したのが図A2である．モデルAが真の時，モデルBが真の時，いず

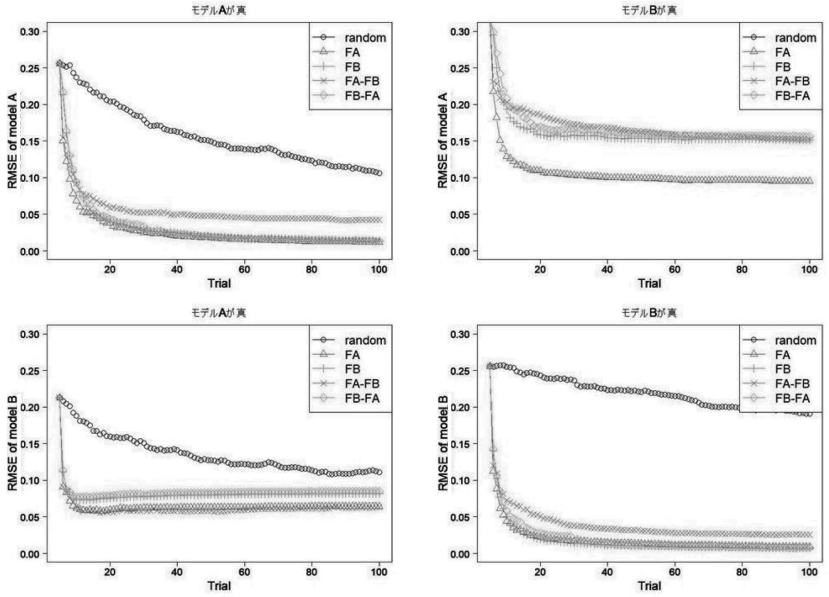


図 A1. DD モデルにおける RMSE
試行ごと（横軸）の割引率パラメータ k における RMSE（縦軸）の結果．左図がモデル A（双曲線関数）が真の場合，右図がモデル B（指数関数）が真の場合の結果である．上図がモデル A で推定した場合，下図がモデル B で推定した場合の結果である．

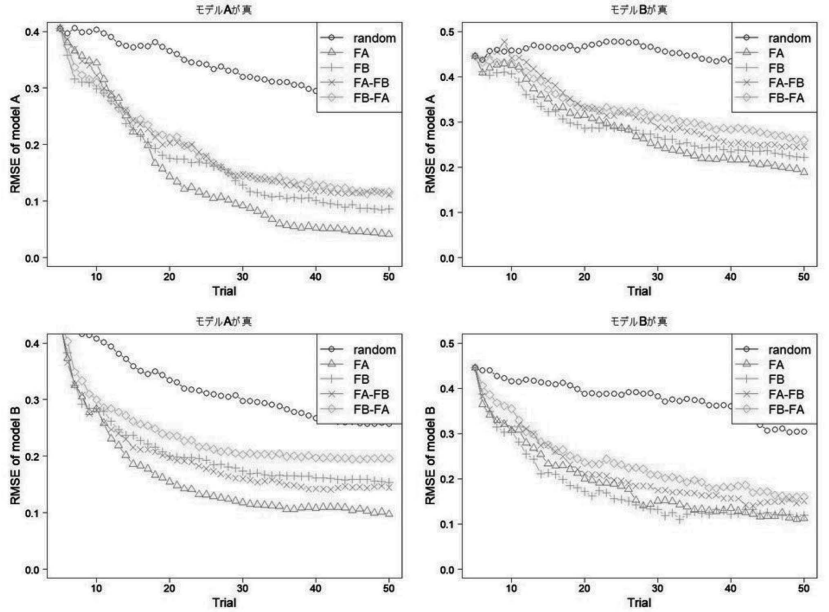


図 A2. CPT モデル，PT モデルにおける RMSE
試行ごと（横軸）のパラメータ γ における RMSE（縦軸）の結果．左図がモデル A（CPT モデル）が真の場合，右図がモデル B（PT モデル）が真の場合の結果である．上図がモデル A で推定した場合，下図がモデル B で推定した場合の結果である．

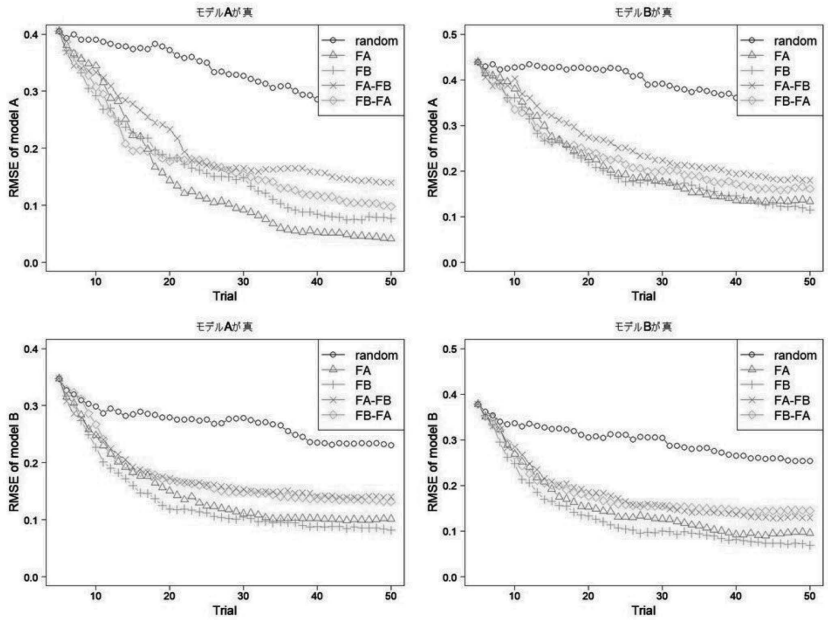


図 A3. Tversky and Kahneman (1992)，Prelec (1998) のモデルにおける RMSE
試行ごと（横軸）のパラメータ γ における RMSE（縦軸）の結果．左図がモデル A（Tversky and Kahneman (1992) モデル）が真の場合，右図がモデル B（Prelec (1998) モデル）が真の場合の結果である．上図がモデル A で推定した場合，下図がモデル B で推定した場合の結果である．

れの状況でも FA-FB 条件や FB-FA 条件で RMSE が高かった．3.3 節のモデルにおける結果を示したのが図 A3 である．図 A2 と傾向は同様である．つまり，FA-FB 条件や FB-FA 条件では RMSE が高かった．また，モデル A が真の時に，モデル A で推定する場合，FA 条件で RMSE が最も低く，モデル B が真の時に, モデル B で推定する場合, FB 条件で RMSE が最も低かった．予測通りではあるが興味深いこととして，従来の CAT である FA 条件や FB 条件は推定精度の意味では最良になりやすいがモデル選択の観点からは最良となりにくい．一方で，FA-FB 条件や FB-FA 条件はモデル選択の観点からは最良となりやすいが，推定精度の意味では最良となりにくいことが示された．